

I N F O R M E D E S E S I Ó N

Del Instinto al Algoritmo

Cómo la IA revoluciona la analítica predictiva aplicada a la estimación de demanda y al forecast comercial



Ponente

Prof. Joaquín Flores

Country Manager Iberia, HubSpot · Faculty PEDC IE Business School

Dirección académica

Prof. Ángel Núñez

Programa PEDC — Dirección Comercial	Edición / Fecha Mayo 2026 — Sesión 2 (18 mayo)
Institución IE Business School · Madrid	Director Académico Prof. Ángel Núñez

RESUMEN EJECUTIVO

La segunda sesión del PEDC, conducida por el Prof. Joaquín Flores, situó la previsión comercial y el cálculo de la demanda como el primer territorio donde la dirección comercial deja de poder sostenerse solo en el instinto. La sesión recorrió, en un único arco narrativo, la lógica del forecast operativo — pipeline, etapas, criterios de salida y ajustes—, el marco macro del cálculo de la demanda — TAM/SAM/SOM y los fracasos recientes de Peloton, Walmart, Nike y H&M—, la mecánica cognitiva de los sesgos que erosionan la calidad de las previsiones humanas, y el rol específico que cuatro tecnologías de inteligencia artificial —machine learning predictivo, series temporales, modelos de clasificación y LLM— pueden jugar como antídoto parcial frente a esos sesgos.

La conclusión rectora del Prof. Flores fue clara: la IA tiene un valor enorme en el proceso comercial, pero su valor depende íntegramente del contexto y del proceso que la empresa sea capaz de aportarle. Sin un pipeline disciplinado, sin criterios de salida objetivos por fase, y sin datos limpios en el CRM, ningún modelo predictivo va a producir un forecast fiable. El 95-98% de las empresas que han incorporado LLM en su operativa diaria no ha visto retorno —según el informe MIT/Harvard citado en la sesión—, no por defectos de la tecnología, sino por ausencia de proceso ordenado en la organización.

Principales conclusiones de la sesión

La previsión comercial ha dejado de ser un ejercicio de estimación cualitativa para convertirse en un proceso de coordinación entre datos estructurados, criterios objetivos por fase y supervisión humana. Los sesgos cognitivos —optimismo, confirmación, recencia, aversión a la pérdida, exceso de confianza, insensibilidad a la magnitud— son sistemáticos y conocidos: la IA bien aplicada los neutraliza, pero introduce los suyos propios. Cuatro tecnologías de IA tienen casos de uso distintos en la función comercial; confundirlas es uno de los errores más frecuentes en la adopción. El cuello de botella de la adopción no es tecnológico sino organizativo: sin proceso, contexto y datos limpios, ningún modelo predictivo aporta valor. El rol del directivo comercial se desplaza del ejecutor del forecast al curador del contexto que alimenta a los modelos, manteniendo el juicio final sobre las decisiones.

BLOQUE I

Del instinto al algoritmo: forecast y demanda

1.1 La dicotomía arte–ciencia en la venta comercial

La sesión arrancó con una pregunta planteada deliberadamente como provocación: ¿la venta es más arte o más ciencia? El Prof. Flores recogió las posiciones del grupo —que oscilaron entre quienes defendieron el peso del intangible relacional y quienes admitieron que la primera cita ya no se consigue sin datos— para introducir la idea-fuerza del bloque: la venta contemporánea no se elige entre arte o ciencia; arranca en la ciencia y termina en el arte. Sin ciencia no hay primera cita, y sin primera cita no hay venta.

Esta tesis sitúa el forecast comercial y el cálculo de la demanda en el extremo más analítico del proceso comercial. Son los lugares donde el instinto —por valioso que sea— produce los errores más caros, y donde, por lo tanto, la incorporación rigurosa de método y de IA debería tener su mayor retorno.

“Sin ciencia no hay primera cita, y sin primera cita no hay venta.”

— Aportación de un participante, recogida y validada por el Prof. Flores

1.2 La venta como ciencia: los principios de Cialdini y la economía conductual

Antes de entrar en el forecast operativo, el Prof. Flores legitimó el argumento científico recordando que una parte sustancial de lo que se atribuye al arte de la persuasión está articulado en literatura académica desde hace décadas. Los seis principios de Robert Cialdini —reciprocidad, escasez, autoridad, compromiso y coherencia, simpatía y prueba social— son procedimientos repetibles cuando se identifican y aplican con disciplina. La economía conductual posterior (Kahneman, Thaler, Ariely, Goleman) profundizó en por qué las decisiones humanas se apartan sistemáticamente de la racionalidad.

La consecuencia operativa para la dirección comercial es que muchas de las habilidades que se daban por irreductiblemente humanas tienen detrás un procedimiento. Y todo procedimiento, una vez explicitado, es automatizable, escalable y susceptible de ser asistido por IA.

1.3 El forecast comercial: por qué importa más allá del Sales Director

El Prof. Flores insistió en que el forecast comercial suele percibirse como una obligación dirigida al jefe de ventas o al VP, cuando en realidad afecta de forma transversal a toda la organización. Una previsión errónea condiciona la experiencia del cliente —porque empuja al comercial a acelerar fases del proceso—, la confianza del mercado en las empresas cotizadas, la capacidad de planificación de las pymes, y el bienestar del propio equipo comercial, sometido a picos de sierra evitables.

Lección aplicada: el forecast es un sistema de información organizativa

El forecast no se hace bien porque lo pida el VP: se hace bien porque coordina decisiones de operaciones, finanzas, marketing y planificación de plantilla. Cada error en la previsión se traduce, aguas abajo, en errores de inventario, contratación o relación con clientes que tienen un coste muy superior al de la propia desviación.

1.4 El pipeline disciplinado: etapas, criterios y por qué el cierre no es 100%

El forecast comercial se construye sobre dos variables conjuntas: el pipeline de oportunidades y la valoración subjetiva del comercial. La parte cuantitativa parte de asignar a cada fase del proceso un porcentaje de probabilidad de cierre, calibrado estadísticamente con datos históricos propios. La parte cualitativa pide al comercial que clasifique cada oportunidad en una de cuatro etapas —sin previsión, puede ser, probable, comprometida (en el original: non-forecasted, best case, most likely, commit).

Variable cuantitativa: pipeline + probabilidad	Variable cualitativa: valoración del comercial
Fase del proceso comercial asignada según criterios objetivos (rol del interlocutor, evento detonante, presupuesto identificado, calendario).	Categoría subjetiva donde el comercial integra contexto que el dato no captura: clima del cliente, señales débiles, dinámica del comité de compra.
Probabilidad estadística estable: por ejemplo, fase de demo = 70%, fase de negociación = 85%, fase de compromiso = 90%.	Las cuatro etapas —sin previsión, puede ser, probable, comprometida— deben ser coherentes con la fase del pipeline donde está la oportunidad.
Permite agregación, comparación interanual, calibración de modelos y, en última instancia, alimentación de IA.	Aporta el contexto que la IA no tiene; es el espacio donde el juicio del comercial sigue siendo insustituible.

El Prof. Flores subrayó un punto operativo crítico: la probabilidad asignada a la última fase, la del compromiso, nunca es del 100%. La convención del 90% recoge la realidad de que, en cualquier proceso comercial maduro, una proporción pequeña pero estable de oportunidades comprometidas se cae en el último tramo —cambio de interlocutor, cambio regulatorio, reorganización interna del cliente, factor externo imprevisto. Reservar ese margen es honestidad estadística, no pesimismo.

Lección aplicada al diseño del pipeline

El pipeline solo es útil cuando cada fase tiene criterios de salida objetivos y escritos: condiciones que el comercial debe verificar antes de avanzar una oportunidad. Sin criterios de salida, la asignación de fase es instintiva, la probabilidad pierde significado, y el forecast agregado se vuelve ruido. La frase del Prof. Flores: “Las instrucciones hacen falta para las personas, pero también para la IA”.

1.5 Ajuste bottom-up vs. top-down: el síndrome de los happy years

Una vez agregadas las cifras del equipo, los ajustes pueden hacerse en dos direcciones. El ajuste bottom-up —desde el comercial hacia arriba— calibra a cada miembro del equipo según su patrón histórico de desviación: si Carlos siempre promete 100 y entrega 60, su forecast se corrige a la baja; si Marta promete 5 y entrega 7, se corrige al alza. El ajuste top-down —desde la dirección hacia abajo— fija el objetivo a partir del plan estratégico y exige al equipo encajar la realidad en él.

Ambos modelos tienen sentido en contextos distintos. El top-down funciona como instrumento de growth mindset y horizonte a tres años; el bottom-up es necesario para el corto y medio plazo, donde la realidad del mercado manda. El Prof. Flores recogió el diagnóstico de un participante, Juan de Dios Herrera (México), sobre la necesidad de un proceso formal de validación entre ambos planos para evitar que el ajuste descendente produzca frustración, desengagement y, paradójicamente, peor desempeño que el predicho.

Advertencia: el síndrome de los happy years

En las revisiones internas del forecast aparece sistemáticamente la tentación de “escuchar lo que queremos escuchar”. El comercial formula preguntas dirigidas al cliente para validar su propia hipótesis, en lugar de preguntas abiertas que descubran necesidades reales. El resultado es un forecast inflado que cuadra a corto plazo pero se desploma al cierre. La disciplina contraria —preguntar siempre primero al cliente qué le preocupa, no validar lo que ya creemos— es uno de los anclajes más prácticos para un equipo comercial con visión de futuro.

BLOQUE II

Demanda, escenarios y la mecánica del error humano

2.1 De la previsión operativa al cálculo de la demanda

El forecast comercial responde a la pregunta de cuánto vamos a vender este trimestre o este año con los datos que tenemos. El cálculo de la demanda, en cambio, responde a una pregunta más estructural: ¿cuánto puede comprar el mercado al que apunto? La fórmula básica que se introdujo en sesión es deliberadamente simple: $Q = N \times q \times p$, donde Q es el mercado total, N el número de compradores potenciales, q la cantidad comprada por comprador y p el precio.

El Prof. Flores ilustró el cálculo con un ejemplo de manual —un servicio de lavado de coches en una zona con 7.500 plazas de aparcamiento, lavado quincenal a 12 € la unidad— para mostrar tanto la utilidad como los límites del modelo. La fórmula da una cifra teórica que sirve de techo, pero rara vez describe el negocio real. Hace falta corregirla por la capacidad de producción, la capacidad de venta y la complejidad del propio canal.

2.2 TAM, SAM, SOM: la matriz del mercado abordable

Cuando los datos son escasos —típicamente en empresas jóvenes o en productos nuevos— el cálculo bruto deja paso a la trilogía TAM/SAM/SOM. Esta metodología disciplinada acepta la incertidumbre y la acota en tres círculos concéntricos: del mercado total alcanzable al mercado que realmente puedo capturar en el período considerado.

TAM — Total Addressable Market	SAM — Serviceable Available Market	SOM — Serviceable Obtainable Market
Mercado total al que el producto o servicio podría dirigirse si no existieran restricciones de canal, capacidad ni competencia.	Subconjunto del TAM accesible desde mi canal de ventas y capacidad operativa actual. Filtra por viabilidad de servicio, no por estrategia.	Subconjunto del SAM que realmente puedo capturar en el horizonte de planificación, dado el panorama competitivo y mis recursos comerciales.
Ejemplo Airbnb: 1,9 trillones USD de gasto anual en viajes y alojamiento a escala global (cifra agregada de la industria).	Filtro: viajeros que reservan online y para los que el precio es factor relevante. Reduce sustancialmente la cifra anterior.	Cuota de mercado real actual: lo que Airbnb factura efectivamente cada año en su geografía y categoría operativa.
Mide la ambición teórica; útil para inversores y para fijar la magnitud de la oportunidad.	Mide la viabilidad operativa; útil para dimensionar canal, equipo y operaciones.	Mide la realidad comercial; es el objetivo razonable del plan a 12-36 meses.

2.3 Entornos volátiles: VUCA, BANI y el caso Silicon Valley Bank

La fiabilidad de cualquier modelo predictivo depende del tipo de entorno en el que se aplica. El Prof. Flores retomó dos marcos que también se trataron en la sesión inaugural del programa: VUCA (volátil, incierto, complejo, ambiguo), nacido en los años 90 en doctrina militar y útil para describir entornos de cambio gestionable, y BANI (frágil, ansioso, no lineal, incomprensible), que describe el entorno post-pandemia donde el cambio incluye rupturas y discontinuidades.

El ejemplo paradigmático del entorno BANI es la quiebra del Silicon Valley Bank en marzo de 2023. Un banco histórico del ecosistema startup, con depósitos masivos de empresas que operan en productos todavía inexistentes, sufrió en pocos días una crisis

bancaria que ningún modelo de riesgo tradicional habría anticipado: cuando la ansiedad —el segundo componente del BANI— se sincroniza por canales digitales, la fragilidad estructural se materializa como crisis sistémica. Frente a este tipo de entornos, el cálculo histórico no basta: hace falta capacidad de adaptación, resiliencia y, sobre todo, conciencia de que los modelos predictivos pueden fallar fuera de la distribución de datos que los entrenó.

2.4 Cuatro casos de fallo en la previsión de la demanda

El Prof. Flores presentó cuatro casos recientes, todos documentados en Harvard Business Review, que ilustran patrones distintos de error en el cálculo de la demanda. Comparten un denominador común: empresas con recursos, datos y equipos analíticos sobrados se equivocaron porque extrapolaron mal el contexto.

Caso	Patrón	Mecanismo del error	Aprendizaje para el directivo
Peloton	Demanda artificial confundida con tendencia estructural	El crecimiento de bicicletas conectadas durante el confinamiento se interpretó como nuevo nivel sostenible, no como pico coyuntural; se invirtió en fábrica e internalización logística.	Distinguir entre demanda coyuntural y demanda estructural antes de comprometer activos de larga duración.
Walmart	Cambio en el patrón de gasto post-shock	El alza de gasto en bienes durante el COVID se proyectó linealmente; al normalizarse la movilidad, el consumidor migró a experiencias y servicios, dejando inventario y almacén saturados.	El patrón histórico inmediato es el peor predictor en la salida de una disrupción; preferir señales de comportamiento.

Nike	Extrapolación de online a offline en cambio de canal	Las ventas directas online se extrapolaron al canal físico; se redujo la red de distribución mayorista y se invirtió en tiendas propias, subestimando la complejidad operativa del retail físico.	Cada canal tiene una economía operativa propia; el éxito en uno no garantiza el éxito en otro aunque el cliente sea el mismo.
H&M	Patrones históricos contra ciclos de tendencia más rápidos	El modelo de producción anticipada basado en datos históricos no capturó la aceleración de microtendencias online; quedó sin stock de los productos demandados y con stock de los que ya no se vendían.	Cuando la velocidad del consumidor supera la velocidad del modelo predictivo, el modelo dejó de funcionar antes de que los datos lo evidencien.

2.5 Kahneman, Sistema 1 y Sistema 2: la herencia del Nobel de Economía a un psicólogo

La sesión introdujo el marco dual de Daniel Kahneman —Premio Nobel de Economía en 2002 siendo psicólogo de formación, lo cual es ya en sí mismo significativo— como hilo conceptual para entender por qué los directivos cometen errores sistemáticos. El Sistema 1 es rápido, instintivo, emocional, automático y subconsciente: nos permite reaccionar a un ruido en la sabana sin pararnos a analizar si es un guepardo o un lince. El Sistema 2 es lento, deliberado, lógico y consciente: nos permite calcular probabilidades, considerar contraejemplos y construir un forecast riguroso.

El dato evolutivo que el Prof. Flores subrayó es que el Sistema 1 es aproximadamente cinco veces más potente que el Sistema 2 —en velocidad y en frecuencia de uso— pero el Sistema 2 consume mucha más energía. La analogía con los modelos de IA es directa: igual que no podemos usar el modelo de mayor coste de tokens para cada consulta, el cerebro no puede activar el Sistema 2 de forma continua. Esta limitación biológica es la base de la mayor parte de los sesgos cognitivos del directivo.

2.6 El catálogo de sesgos cognitivos del directivo comercial

Sesgo	Mecánica	Dónde golpea en el forecast	Antídoto operativo
Optimismo	Sobreestimación sistemática del propio desempeño, sobre todo cuando el objetivo es difícil.	Forecast inflado al cierre; planes de expansión sin cobertura de recursos.	Calibración histórica del comercial: corregir su forecast con su patrón de desviación pasada.
Confirmación	Damos más peso a información que confirma	Preguntas dirigidas al cliente; lectura selectiva de	Disciplina de preguntas abiertas; revisión cruzada

	nuestras creencias que a información que las contradice.	señales débiles en la cuenta.	del forecast por otro miembro del equipo.
Recencia	Lo más reciente se percibe como lo más probable de cara al futuro.	Buen Q1 → forecast inflado del Q2 sin variación de base instalada o pipeline.	Comparación contra series de varios trimestres; medias móviles en lugar de último dato.
Aversión a la pérdida (sunk cost)	Lo invertido pesa más que lo razonable; nos cuesta abandonar oportunidades en las que ya pusimos meses de esfuerzo.	Oportunidades muertas que siguen en pipeline; reuniones de seguimiento sin progreso real.	Criterios objetivos de descalificación; revisiones periódicas que obligan a archivar oportunidades estancadas.
Exceso de confianza	Damos a nuestra lectura del cliente más peso del que objetivamente merece.	El comercial defiende un forecast que el dato no respalda porque “me ha dicho que sí”.	Triangulación con el CRM: ¿hay datos objetivos que sustenten esta valoración? Si no, baja un nivel.
Insensibilidad a la magnitud	Los seres humanos manejan mal las cifras grandes; un ahorro de 6€ en una compra de 1.000€ se percibe como insignificante, pero los mismos 6€ en una compra de 10€ se persiguen.	Decisiones de inversión y de pricing que ignoran el impacto agregado de pequeños porcentajes en cifras grandes.	Reformular siempre en porcentaje y en términos absolutos; presentar series temporales para visualizar el impacto compuesto.

BLOQUE III

La IA como antídoto de los sesgos (y sus propios límites)

3.1 Cuatro tecnologías de IA aplicadas al proceso comercial

Para situar correctamente el rol de la inteligencia artificial en la previsión comercial y el cálculo de la demanda, el Prof. Flores diferenció cuatro tecnologías distintas que con frecuencia se confunden bajo el paraguas genérico de “IA”. Cada una tiene un caso de uso específico, fortalezas distintas y, sobre todo, modos de fallo distintos.

Tecnología	Para qué brilla	Cuándo falla	Caso de uso típico
Machine Learning Predictivo	Encontrar patrones y correlaciones en grandes volúmenes de datos estructurados (Excel).	Cambios estratégicos, mercados nuevos o ausencia de histórico; no entiende causalidad, solo correlación.	Detección de fraude por correlación entre variables; segmentación de clientes; scoring de leads.

Series temporales	Detectar tendencias, ciclos y estacionalidad cuando el tiempo es la variable clave.	Disrupciones externas, cambios regulatorios o eventos inesperados que rompen la serie histórica.	Forecast de consumo eléctrico; previsión de ventas estacionales; análisis de tendencia de mercado.
Modelos de clasificación	Decisión binaria o multiclase basada en ejemplos históricos: ¿este caso encaja en el patrón A o B?	Eventos atípicos que no encajan en ninguna clase aprendida; alta tasa de falsos positivos cuando el coste de error es alto.	Detección de fraude en pago con tarjeta; predicción de churn de seguros; cualificación automática de leads.
LLM (modelos generativos)	Interpretar contexto humano, generar hipótesis, redactar y resumir en lenguaje natural.	Cálculo cuantitativo; consistencia: respuesta no determinista —dos preguntas idénticas pueden dar dos respuestas distintas; alucinaciones cuando falta contexto.	Resumir un cliente antes de la reunión; redactar correos personalizados; analizar transcripciones de llamada.

Lección aplicada: no confundir las cuatro tecnologías

Pedirle a un LLM que prediga la demanda de un trimestre es como pedirle a una serie temporal que escriba un correo personalizado: cada herramienta tiene un dominio en el que brilla y otros en los que produce ruido. El directivo comercial no necesita dominar la matemática de cada modelo, pero sí saber qué tecnología corresponde a cada problema. El error frecuente en la adopción es comprar la herramienta de moda y aplicarla al problema equivocado.

3.2 Tres modos de adopción empresarial de la IA

El Prof. Flores describió las tres vías por las que las empresas están incorporando IA en su operativa comercial, ordenadas por viabilidad y por volumen de datos requerido.

Funcionalidad integrada	Servicio externo	IA propia con capacidad interna
La IA viene embebida en el CRM o en la herramienta de trabajo: capacidades de previsión, scoring, próxima mejor acción, asistente conversacional.	La empresa contrata a un proveedor externo que entrena un modelo sobre sus datos para un caso de uso específico (forecast, segmentación, fraude).	La empresa desarrolla y opera modelos propios con su equipo de ciencia de datos y su infraestructura computacional.
Accesible para cualquier organización con un CRM moderno; el contexto se aporta a través de la calidad de los datos cargados.	Accesible para empresas con volumen y limpieza de datos suficiente; el conocimiento del dominio lo aporta el proveedor.	Solo viable para grandes corporaciones con volumen de datos masivo, equipo técnico propio y casos de uso de alto valor estratégico.

Riesgo bajo, retorno medio; depende íntegramente de la disciplina del equipo al introducir datos en la herramienta.	Riesgo medio, retorno medio-alto; el proveedor estandariza, pero el modelo se va personalizando en el tiempo según los datos del cliente.	Riesgo alto, retorno potencialmente muy alto; muy pocas empresas tienen volumen suficiente para que sea rentable construir desde cero.
---	---	--

3.3 Inmediatez y proactividad: el cambio de paradigma

El cambio cualitativo respecto a la generación anterior de CRM no está en la potencia analítica —que ya existía— sino en dos dimensiones nuevas: la inmediatez con la que el sistema recalcula, y la proactividad con la que avisa. El forecast deja de ser una foto que se actualiza cuando el directivo se sienta a revisarlo y pasa a ser un flujo continuo que dispara alertas: una llamada en la que el cliente expresa duda baja automáticamente la probabilidad asignada a la oportunidad y notifica al director comercial para que actúe. Es lo que el Prof. Flores describió como pasar del “gato de Rodin” —un análisis que solo ocurre cuando alguien lo activa— a un sistema vivo.

Este cambio abre un repertorio de casos de uso que antes no eran factibles: prospección automatizada con personalización contextual, alertas sobre cambios en la cuenta del cliente (cambio de organización, noticias relevantes), priorización dinámica de la cartera del comercial. La consecuencia operativa es que el tiempo del comercial puede redistribuirse: el 67% que según Salesforce se dedica a tareas no comerciales puede comprimirse, liberando capacidad para la conversación de valor que sigue requiriendo el directivo.

95–98%

de empresas que han pilotado LLM en su operativa diaria no ha visto retorno medible. Informe MIT/Harvard citado en sesión.

3.4 La trampa del 95-98%: por qué fracasan los LLM en la mayoría de las empresas

El Prof. Flores citó un estudio reciente (MIT en colaboración con Harvard) según el cual entre el 95% y el 98% de las empresas que han incorporado modelos de lenguaje en su operativa diaria no han visto retorno medible en productividad. El dato, en su momento, provocó una caída bursátil notable de las grandes tecnológicas asociadas a la IA generativa.

La explicación del Prof. Flores no se centró en la tecnología sino en la organización. Las empresas que fracasan no fallan porque el LLM funcione mal; fallan porque despliegan la herramienta sin tener un proceso comercial ordenado detrás. Sin un pipeline disciplinado, sin criterios de salida por fase, sin un CRM con datos limpios y sin un contexto estructurado que alimente al modelo, el LLM produce respuestas verosímiles pero sin valor —o, peor, alucinaciones con apariencia de dato.

Advertencia: el problema no es la herramienta, es la base

El paralelismo histórico que ofreció el Prof. Flores —diecisiete años vendiendo CRM en HubSpot— es revelador: muchas empresas compraron CRM en los años 2010 sin tener un proceso comercial definido, y el resultado fue idéntico al de hoy con la IA. La conclusión es que la adopción de IA debe ir precedida, no seguida, por un trabajo de diseño de procesos. Comprar la herramienta antes de tener el proceso es desperdicio.

3.5 El nuevo rol del directivo comercial: curador del contexto

La síntesis del bloque, recogida en el cierre conjunto del Prof. Flores y el Prof. Núñez, sitúa el rol del directivo comercial en una nueva posición. La IA aporta el dato; el directivo aporta el contexto. Pero el contexto no es algo que se transfiera al modelo una vez: es algo que se construye y se mantiene a través de dos canales paralelos.

El primero es el contexto corporativo, que se transmite a la IA a través de la integración del CRM, las bases de datos comerciales y los sistemas de la compañía. Este contexto es el que permite que cuando un modelo recomienda una próxima acción, la recomendación esté informada por la historia real de la cuenta. El segundo es el contexto de proyecto, el que el directivo aporta cuando trabaja con la IA en su workspace —los archivos que carga, las instrucciones que da, los proyectos que organiza.

El Prof. Núñez cerró este bloque con una imagen recogida durante la sesión por el participante José Ángel Sánchez: la IA todavía puede recomendar setas venenosas si no se le proporciona el contexto adecuado. La función del directivo es asegurar que el contexto delimite el espacio en el que la IA opera —los ingredientes correctos, en la cantidad correcta, con las restricciones correctas— para que su recomendación no solo sea verosímil sino utilizable.

REFLEXIÓN FINAL

El arte que sobrevive al algoritmo

La sesión cerró con una idea que el Prof. Núñez recogió y enmarcó en el contexto general del programa: la profesión comercial es de las pocas que, por el momento, sorteas el riesgo existencial de sustitución que la IA plantea a otras funciones de conocimiento. La razón es que el final del funnel sigue requiriendo una interacción humana sobre la que pivota la confianza del cliente, y esa confianza —al menos en B2B consultivo, en servicios complejos y en cualquier venta con alta carga relacional— no es replicable por ningún modelo actual.

Pero esta supervivencia no es gratuita. Exige al directivo comercial dos disciplinas nuevas. La primera es la disciplina de proceso: pipeline ordenado, criterios de salida objetivos, datos limpios en el CRM, definición clara de los puntos donde la IA puede asistir y los puntos donde solo puede contaminar. La

segunda es la disciplina de contexto: construir y mantener el contexto que la IA necesita para producir valor, y asumir el juicio final sobre las decisiones donde el dato es insuficiente.

La frase de cierre del Prof. Flores, que conecta con la idea-fuerza que abrió la sesión, sintetiza el movimiento que el directivo comercial está llamado a hacer en los próximos años: del instinto al algoritmo, sí, pero no para reemplazar el primero por el segundo, sino para que el algoritmo libere al instinto del peso de las tareas en las que sistemáticamente se equivoca, y le devuelva su lugar legítimo —el de la conversación de valor, el de la lectura del cliente, el del juicio final.

“La inteligencia artificial nos puede dar el dato. Todavía no le dejamos, casi nunca, tomar las decisiones. La decisión sigue siendo humana —y eso, en nuestra profesión, sigue siendo el activo central.”

— Prof. Joaquín Flores, cierre de la sesión

REFERENCIAS

Fuentes citadas en la sesión

Ariely, D. Predictably Irrational: The Hidden Forces That Shape Our Decisions. HarperCollins, 2008.

Cialdini, R. Influence: The Psychology of Persuasion. Edición revisada, Harper Business, 2006.

Kahneman, D. Thinking, Fast and Slow. Farrar, Straus and Giroux, 2011.

Thaler, R. y Sunstein, C. Nudge: Improving Decisions About Health, Wealth, and Happiness. Yale University Press, 2008.

MIT / Harvard Business Review. Estudio sobre adopción empresarial de modelos LLM y retorno en productividad (informe citado en sesión, 2024–2025).

Harvard Business Review. Artículos sobre los casos Peloton, Walmart, Nike y H&M en relación con errores de previsión de demanda.

Salesforce. State of Sales Report. Dato del 67% del tiempo del comercial dedicado a tareas no comerciales.

HubSpot. Pipeline de etapas y criterios de salida (referencia de proceso comercial presentada en sesión).